Detección de fraude bancario mediante KDD



Proyecto Final SINF-633

Michelle Moreira Quirós

UCenfotec · Octubre 2026

Made with GAMMA

Contexto y objetivo del proyecto

5.000

Transacciones analizadas

109

Fraudes identificados

2,18%

Tasa de fraude

Objetivo

Identificar patrones que permitan distinguir transacciones legítimas de posibles fraudes.

Desafío

Detectar fraudes sin generar demasiadas falsas alarmas que afecten a los clientes.

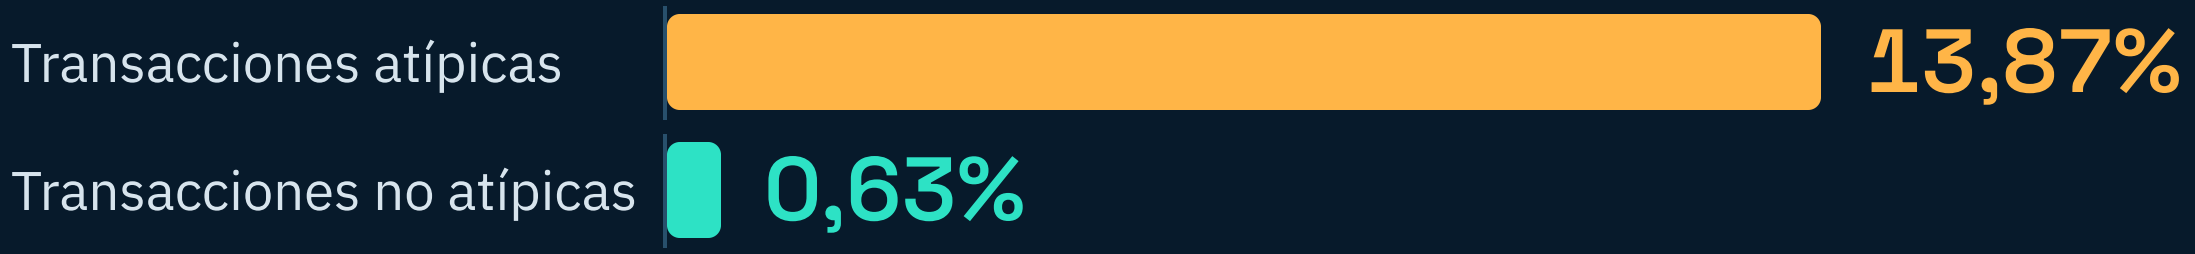
Made with GAMMA

CALIDAD DEL REGISTRO

El preprocesamiento conserva todos los registros y revela una señal en los atípicos

0	584	5.000
Duplicados	Montos atípicos	Registros conservados

TASA DE FRAUDE



Se trataron valores faltantes en edad, canal y región, conservando todas las transacciones

Made with GAMMA

Transformación de datos

TRANSFORMACIÓN LOGARÍTMICA

8,660 → 1,642

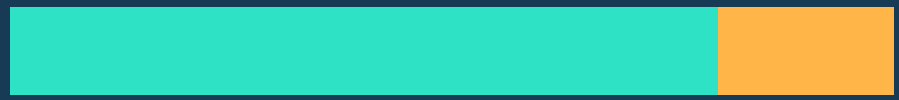
Reducción de la asimetría del monto mediante np.log1p()



PREPARACIÓN DE VARIABLES

Ingeniería de atributos, codificación categórica y escalado mediante Pipeline

DIVISIÓN DE DATOS



80% entrenamiento / 20% prueba

Estratificada

Made with GAMMA

K-Means y DBSCAN

K-MEANS

k = 2

Mejor resultado de silueta entre k = 2 y k = 10

DBSCAN

62

anomalías detectadas

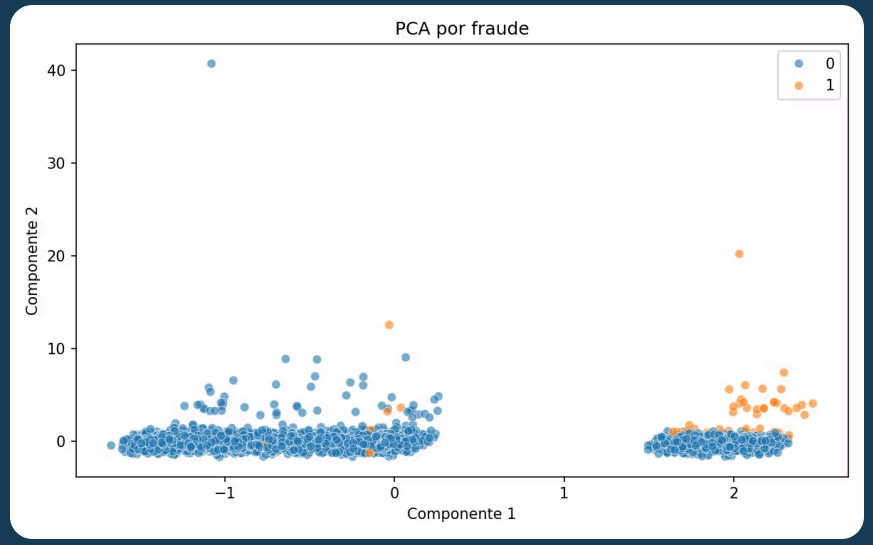
Tasa de fraude según DBSCAN



Made with GAMMA

Análisis de Componentes Principales (PCA)

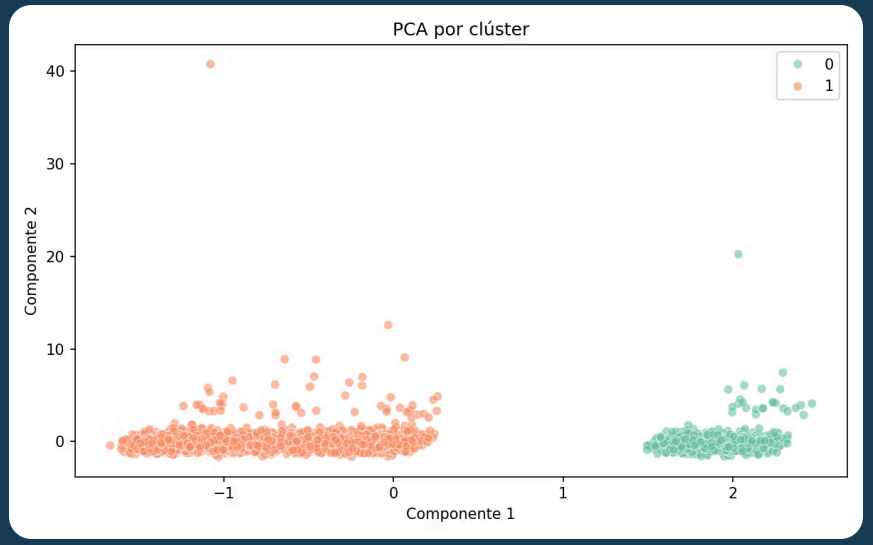
PCA POR FRAUDE



32,4%

Varianza explicada con 2 componentes

PCA POR CLÚSTER



44,6%

Varianza explicada con 3 componentes

Made with GAMMA

Modelos de detección de fraude

Los modelos representan dos prioridades operativas distintas

Regresión logística con class_weight balanced y Random Forest, ambos entrenados con Pipeline.

PRIORIZAR DETECCIÓN

recall

Regresión logística

86,4%

de recall.

Detectó una mayor proporción de transacciones fraudulentas, pero generó más falsas alarmas

Buscar recall alto para capturar más fraudes.

REDUCIR FALSAS ALARMAS

precision

Random Forest

100%

de precisión en el conjunto de prueba.

Sus alertas fueron más precisas, aunque identificó una menor proporción de fraudes

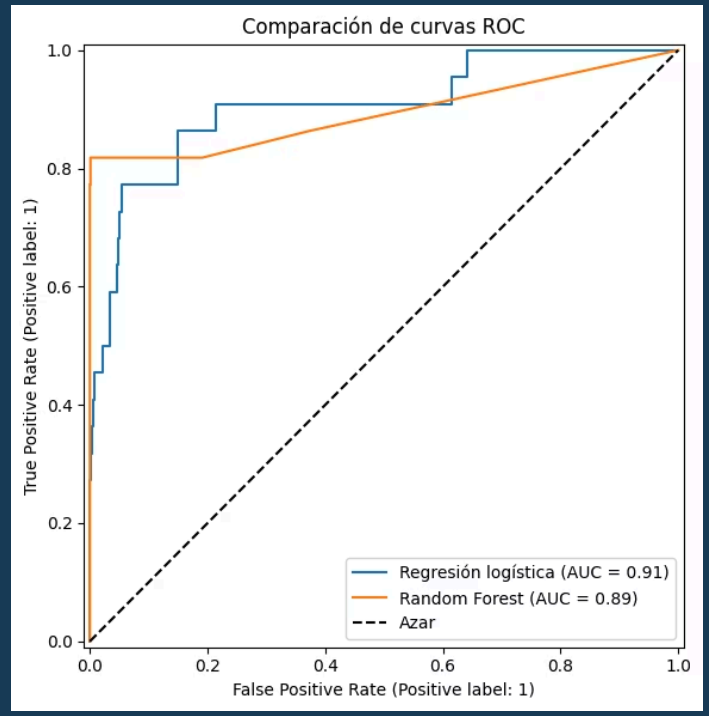
Priorizar precision alta para que menos transacciones legítimas se marquen como fraude.

Made with GAMMA

Evaluación de modelos predictivos

Métrica	Regresión logística	Random Forest
Accuracy	83,6%	99,5%
Precision	**10,6%**	**100,0%**
Recall	**86,4%**	**77,3%**
F1-score	18,8%	87,2%
ROC-AUC	0,905	0,893

CURVA ROC COMPARATIVA



La regresión logística detecta más fraudes; Random Forest reduce las falsas alarmas y obtiene mayor F1-score

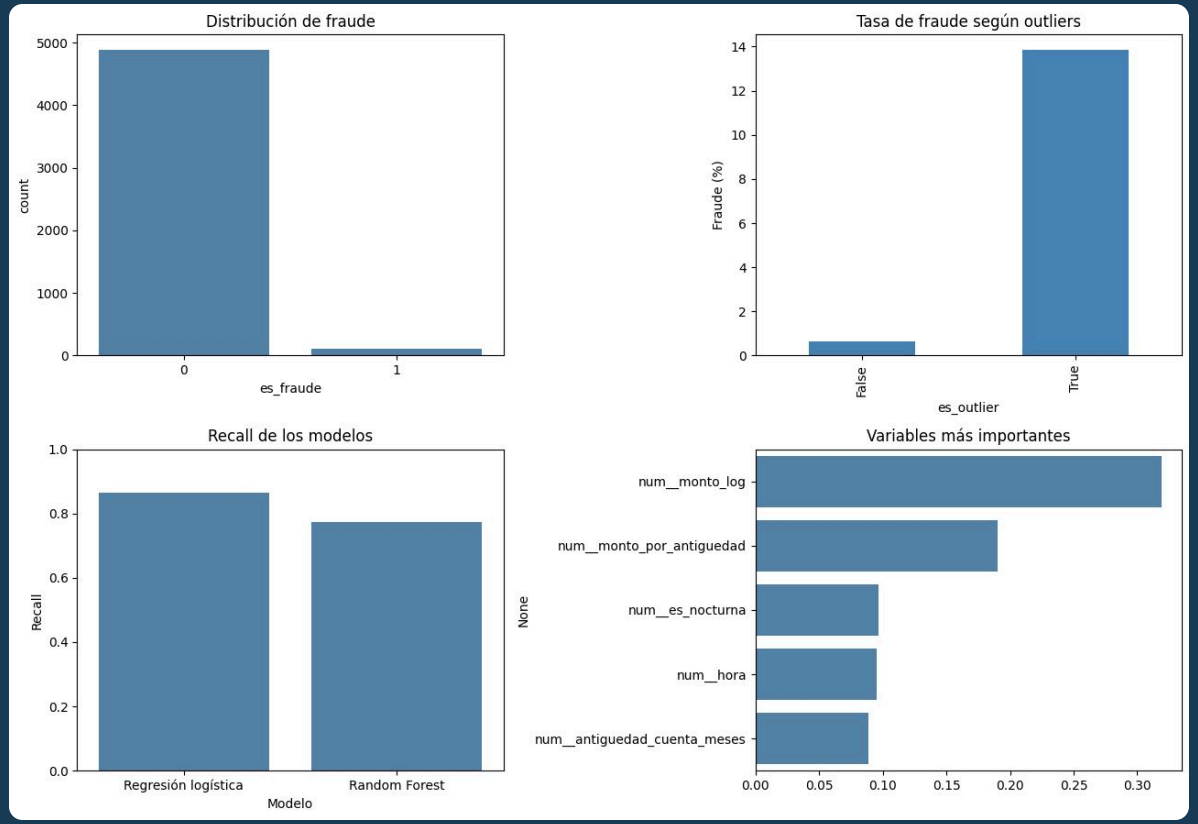
Made with GAMMA

Variables más importantes en la detección de fraude

31,9%
Monto logarítmico

19,0%
Monto por antigüedad

9,6%
Transacción nocturna



RESUMEN VISUAL DE LOS RESULTADOS

Made with GAMMA

Conclusiones y recomendaciones

HALLAZGO

Random Forest genera menos falsas alarmas; regresión logística detecta más fraudes.

DECISIÓN

Evaluar los costos de falsos positivos y falsos negativos.

LIMITACIÓN

Validar con datos nuevos antes de implementar.

CONCLUSIÓN

KDD convierte datos transaccionales en información útil para apoyar decisiones.

Made with GAMMA