Proyecto final SINF-633

# Detección de fraude bancario mediante KDD

## 1. Resumen ejecutivo

Se aplicaron las cinco etapas del proceso KDD a 5.000 transacciones bancarias, con 109 casos de fraude (2,18%). El análisis buscó identificar patrones y comparar modelos para apoyar la detección de operaciones sospechosas. Los montos atípicos presentaron mayor proporción de fraude y los dos clasificadores mostraron diferencias relevantes entre detectar más casos y generar menos alertas incorrectas.

## 2. Datos y metodología

Selección. Se cargaron 11 columnas del archivo de transacciones y se exploraron tipos y distribución de la variable objetivo es_fraude. Para modelar se descartaron identificadores y se trabajó con características del monto, cuenta, horario, tipo de transacción, canal y región.

Preprocesamiento. Se encontraron 71 valores faltantes en edad, 59 en canal y 79 en región; no hubo filas duplicadas. Se aplicó imputación por mediana y moda. Para los clasificadores se preservaron los valores faltantes originales de esas columnas, de modo que la imputación se ajuste dentro del Pipeline sobre los datos de entrenamiento. Se identificaron 584 montos atípicos con IQR sin eliminarlos. La transformación logarítmica redujo la asimetría de 8,660 a 1,642.

Transformación. Se derivaron hora, indicador de transacción nocturna y monto relativo a antigüedad; también se utilizó el monto logarítmico. Se realizó una división estratificada 80/20, con semilla 42, y un ColumnTransformer con imputación, StandardScaler y OneHotEncoder. Se revisaron correlaciones numéricas para detectar posibles relaciones fuertes.

Minería. Se aplicaron K-Means (k de 2 a 10, método del codo y silueta), DBSCAN, PCA y dos modelos de clasificación: regresión logística y Random Forest. Se evaluaron accuracy, precision, recall, F1 y ROC-AUC sobre el conjunto de prueba.

## 3. Resultados cuantitativos

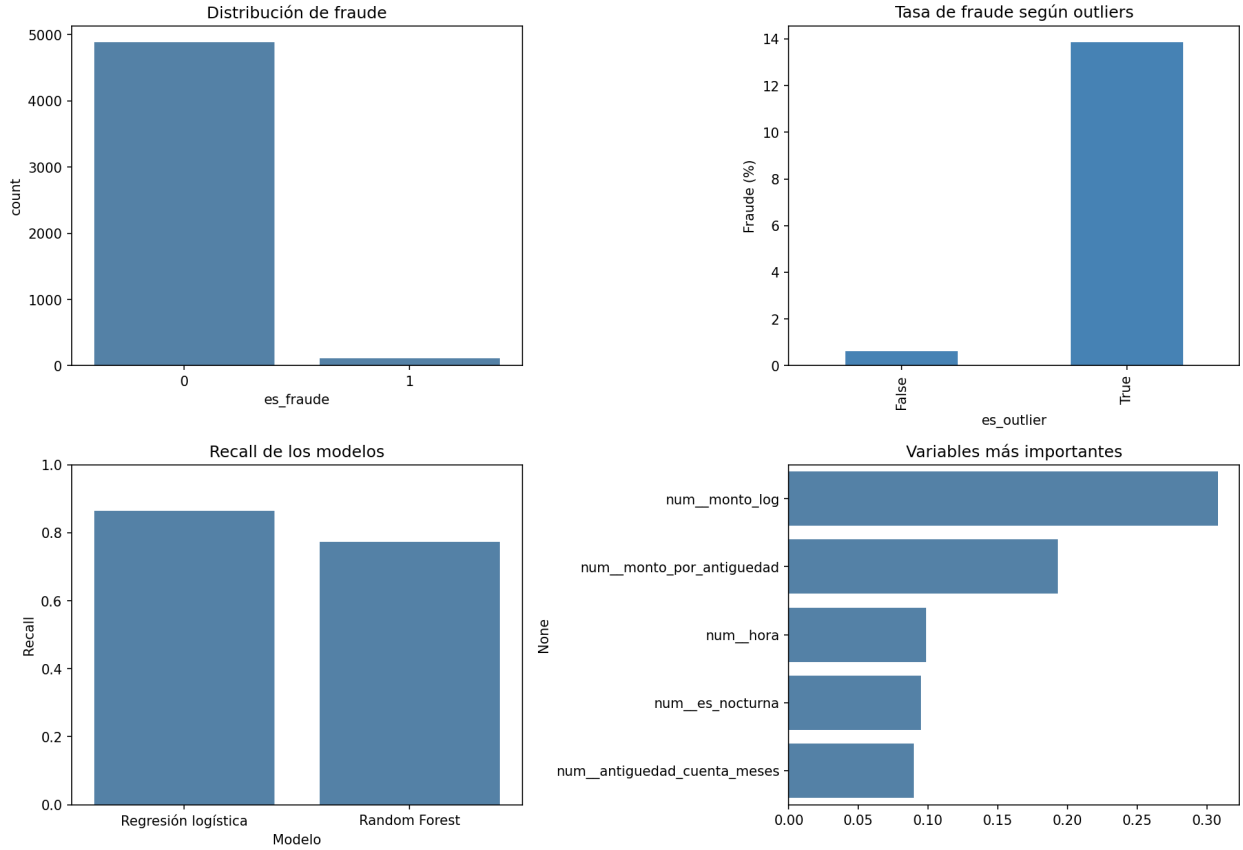
| Modelo | Accuracy | Precision | Recall | F1 | ROC-AUC |
|---|---|---|---|---|---|
| Regresión logística | 0,836 | 0,106 | 0,864 | 0,188 | 0,905 |
| Random Forest | 0,995 | 1,000 | 0,773 | 0,872 | 0,893 |

La regresión logística detectó una proporción mayor de fraudes (recall de 86,4%) y obtuvo ROC-AUC de 0,905, pero su precisión fue de 10,6%. Random Forest tuvo una precisión de 100% y un F1 de 0,872, aunque detectó el 77,3% de los fraudes. Dado el desbalance de clases, la exactitud (accuracy) por sí sola no refleja todos los costos del error.

Agrupamiento y reducción. K-Means seleccionó k = 2 mediante silueta entre los valores evaluados de 2 a 10. DBSCAN identificó 62 anomalías: 22,58% fueron fraudulentas, frente a 1,85% de los registros no clasificados como anomalías. PCA explicó el 32,4% de la variabilidad con dos componentes y el 44,6% con tres. Se visualizaron los componentes por fraude y por clúster.

Valores atípicos. De las 584 transacciones con montos atípicos, el 13,87% presentó fraude, frente al 0,63% de los montos no atípicos. Esta asociación justifica conservar esas observaciones.

## 4. Visualizaciones principales




Dashboard de distribución de fraude, montos atípicos, recall y principales variables del modelo.

## 5. Interpretación y recomendaciones

Los resultados indican que el monto y algunas características horarias son útiles para distinguir operaciones. Las cinco importancias más altas en Random Forest fueron: monto_log (31,9%), monto_por_antiguedad (19,0%), es_nocturna (9,6%), hora (9,5%) y antiguedad_cuenta_meses (8,9%). Son importancias predictivas, no relaciones causales.

Se propone evaluar Random Forest cuando sea importante limitar las falsas alarmas, y considerar la regresión logística si la prioridad es recuperar la mayor cantidad de fraudes. Las señales de montos atípicos y anomalías DBSCAN podrían apoyar la priorización de revisiones. Antes de utilizar estos resultados en un banco sería necesario estimar el costo de los fraudes omitidos, el costo operativo de las alertas y ajustar el umbral de decisión.

## 6. Limitaciones y próximos pasos

El fraude representa solo el 2,18% de los registros, lo que exige cuidado al interpretar accuracy y precision. DBSCAN se ejecutó con una configuración inicial de parámetros. Los dos o tres componentes PCA no explican toda la información. También se necesita comprobar el rendimiento con transacciones de otros períodos y revisar la estabilidad de los modelos antes de cualquier aplicación operativa.

La limpieza exploratoria y ciertas variables derivadas se calcularon antes de la separación entrenamiento/prueba; aunque la imputación de edad, canal y región de los clasificadores se ajustó dentro del Pipeline, una validación de producción debe revisar el cálculo de cada transformación. No se plantea que los modelos estén listos para implementarse directamente.

Fuente: resultados y visualizaciones del notebook Proyecto_KDD_Fraude(1).ipynb proporcionado para este proyecto.